Взаимная информация по выборке: что это, зачем, и как её оценивают нейросетями

Лонгрид-разбор тестового задания «Вариационные оценки» (MINE и CLUB)

Для человека, который знает ML, но впервые слышит об оценке взаимной информации

Как читать этот лонгрид. Раздел 1 — зачем это всё нужно (мотивация, 15 мин). Раздел 2 — термины и формулы с численными примерами (30 мин). Раздел 3 — разбор самого задания: что обучаем, какой таргет, как проверяют (30 мин). Раздел 4 — два готовых файла с кодом, которые можно запустить в Google Colab и потрогать числа руками (1 час). Раздел 5 — план на 8–10 ноября и мини-список литературы. Файлы-спутники: `00_baseline_colab.py` (бейзлайн без нейросетей), `01_mine_minimal.py` (минимальный MINE на PyTorch) и `02_club_minimal.py` (минимальный CLUB на PyTorch).

Содержание

1 Отрасль: что мы делаем и зачем **1**
- 1.1 Где мы находимся . . . 1
- 1.2 Зачем оценивать ВИ: сценарии с примерами . . . 1
- 1.3 Ключевая идея направления: нижняя или верхняя . . . 2

2 Термины и метрики **2**
- 2.1 Энтропия: сколько «сюрприза» в величине . . . 2
- 2.2 Совместная и условная энтропии . . . 3
- 2.3 Дивергенция Кульбака–Лейблера (KL) . . . 3
- 2.4 Взаимная информация . . . 3
- 2.5 Гауссовский случай — наш рабочий эталон . . . 4
- 2.6 Инвариантность к биекциям . . . 4
- 2.7 «Что мы предсказываем» — главное против заблуждений . . . 4
- 2.8 Как мерить качество оценки . . . 4
- 2.9 Словарь терминов задания . . . 5

3 Задача: что нужно сделать **5**
- 3.1 Что дано и что требуется . . . 5
- 3.2 MINE: нижняя оценка . . . 5
- 3.3 CLUB: верхняя оценка . . . 6
- 3.4 Таргеты: сводка «кто что учит» . . . 7
- 3.5 Валидация по заданию . . . 7
- 3.6 Что сдавать и как оценивают . . . 8

4 Бейзлайн: потрогать числа руками **8**
- 4.1 Зачем бейзлайн . . . 8
- 4.2 Что внутри файла . . . 9
- 4.3 Чеклист понимания после прогона . . . 9
- 4.4 Следующий шаг: минимальный MINE . . . 9
- 4.5 Ещё один шаг: минимальный CLUB . . . 9

5 План до 10 ноября **10**
- 5.1 С чего начать изучение темы . . . 10

1 Отрасль: что мы делаем и зачем

1.1 Где мы находимся

Задание относится к области **оценки взаимной информации** (mutual information estimation) — направлению на стыке теории информации, математической статистики и глубокого обучения. Взаимная информация (ВИ, mutual information, MI) $I(X;Y)$ — это *универсальная мера статистической зависимости* между случайными величинами X и Y. В отличие от коэффициента корреляции Пирсона, который видит только *линейную* связь, ВИ ловит любую зависимость, включая нелинейную.

Почему корреляции мало. Пример 1: $X \sim \mathcal{N}(0,1)$, $Y = X^2$. Связь абсолютно детерминированная, но $\mathrm{corr}(X,Y) = 0$ — из-за симметрии распределения квадрат «не коррелирует» со своим аргументом, хотя полностью им определяется. Пример 2: точки, лежащие на окружности: $Y = \sin\Theta$, $X = \cos\Theta$ — корреляция нулевая, зависимость полная. ВИ в обоих случаях больше нуля (а для детерминированной связи — бесконечна). Вывод: если мы хотим мерить «насколько связаны» признаки, изображения или представления, корреляция — слишком грубый инструмент, нужна ВИ.

Историческая рамка. ВИ определил Шеннон в 1948 году; долгое время её считали в основном в дискретных задачах (отбор признаков, анализ текстов, филогенетика). В глубоком обучении интерес к ВИ взорвался после серии работ: InfoMax-принцип (Linsker, 1988), InfoGAN (Chen et al., 2016), **MINE** (Belghazi et al., ICML 2018), InfoNCE (van den Oord et al., 2018) и **CLUB** (Cheng et al., ICML 2020). Именно MINE и CLUB предлагается реализовать в задании.

1.2 Зачем оценивать ВИ: сценарии с примерами

Везде одна и та же механика: есть пара случайных величин, и нужно *число* — насколько сильно они связаны. Разница только в том, *что* потом с этим числом делают.

- **Обучение представлений (InfoMax).** Хотим, чтобы представление $z = f(x)$ сохраняло максимум информации о входе x: максимизируем $I(X;Y)(x;z)$ (Deep InfoMax, 2019). Нужна оценка ВИ, чтобы её дифференцировать и гнать градиентом вверх.
- **InfoGAN.** Хотим управлять факторами генерации: максимизируем $I(X;Y)(c;G(z,c))$ между кодом фактора c и изображением — сеть учится «проявлять» каждый фактор в отдельной оси латентного пространства.
- **Контрастивное обучение (SimCLR, CPC).** Лосс InfoNCE — это, по сути, нижняя граница ВИ между представлением и данными: «тяни похожие пары друг к другу, расталкивай разные». Всё это семейство — родственники MINE.
- **Отбор признаков и сжатие.** Выбрать из тысячи признаков те, у которых максимальная $I(X;Y)(\text{признак};\text{таргет})$. Information Bottleneck: сжать x в z так, чтобы $I(X;Y)(x;z)$ была мала, а $I(X;Y)(z;y)$ велика.
- **Unlearning, регуляризация, приватность.** Хотим *уменьшить* зависимость между представлением и чувствительным признаком (пол, возраст, источник данных). Здесь нужно *минимизировать* ВИ — и критически важно, какой границей мы пользуемся (см. ниже).
- **Нейронаука.** Оценка информации, которую нейроны несут о стимуле (спайковые данные).

1.3 Ключевая идея направления: нижняя или верхняя

Точное значение $I(X;Y)$ на реальных данных почти никогда не вычислить — нужны плотности $p(x,y)$, $p(x)$, $p(y)$, а у нас лишь выборка пар $\{(x_i,y_i)\}_{i=1}^N$ (картинки, тексты, латентные коды). Оценивать плотности в высокой размерности — отдельная тяжёлая задача (проклятие размерности). Поэтому современный подход — **вариационные границы**: строим величину, которую можно посчитать прямо по выборке, и которая

- либо *гарантированно меньше* истинной ВИ (**нижняя оценка**, lower bound);
- либо *гарантированно больше* (**верхняя оценка**, upper bound).

Почему важно направление границы? Если вы *максимизируете* ВИ (сжатие, отбор признаков, InfoMax) и оптимизируете нижнюю границу, то истинная ВИ при этом тоже растёт — граница «тащит» её вверх. А вот если вы *минимизируете* ВИ (unlearning) и оптимизируете *нижнюю* границу, то она может падать, а истинная ВИ — расти: сеть просто «сжульничает», обрушив границу. Для минимизации нужна *верхняя* граница. Поэтому в задании написано: нижние оценки — для максимизации (MINE), верхние — для минимизации (CLUB).

Пример из жизни. Вы хотите сделать представление, из которого невозможно восстановить пол пользователя. Вы обучаете сеть минимизировать $\hat{I}_{\text{MINE}}$ (нижнюю границу). Сеть находит вырожденного критика, у которого $\hat{I}_{\text{MINE}}$ около нуля, — вы довольны. Но настоящая зависимость никуда не делась: при атаке по восстановлению пола точность остаётся высокой. Правильный инструмент для этой задачи — верхняя оценка CLUB: пока она падает, падает и истинная ВИ.

Классические не-нейросетевые оценки ВИ (гистограммы, kNN-оценка Кржижанова–Штёгбауэра–Грассбергера, KSG) работают только в малой размерности — их используют как референс, с них мы и начнём в бейзлайне (раздел 4).

2 Термины и метрики

2.1 Энтропия: сколько «сюрприза» в величине

Для дискретной X с вероятностями $p(x)$:

$$H(X) = -\sum_x p(x) \log p(x) = \mathbb{E}[-\log p(X)].$$

Интуиция: $-\log p(x)$ — это «сюрприз» (чем маловероятнее исход, тем больше), а энтропия — средний сюрприз, мера неопределённости. Если логарифм натуральный, единица измерения — **нат**; если двоичный — **бит**. Перевод: 1 нат $= 1/\ln 2 \approx 1.443$ бит.

Числа. Честная монета: $H = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1$ бит. Кривая монета (орёл с вероятностью 0.9): $H = -(0.9 \log_2 0.9 + 0.1 \log_2 0.1) = 0.469$ бит — неопределённости меньше, потому что почти всегда орёл. Честный кубик: $H = \log_2 6 \approx 2.585$ бит.

Для непрерывных величин используют дифференциальную энтропию $h(X) = -\int p(x) \log p(x)\, dx$; она может быть отрицательной (узкое распределение), но *разности* энтропий, которые нам нужны, — обычные положительные величины. Для гауссианы: $h(\mathcal{N}(\mu, \sigma^2)) = \frac{1}{2} \ln(2\pi e\, \sigma^2)$.

2.2 Совместная и условная энтропии

Совместная энтропия пары: $H(X, Y) = -\sum_{x,y} p(x, y) \log p(x, y)$ — неопределённость обоих вместе. Условная: $H(X \mid Y) = \sum_y p(y)\, H(X \mid Y = y)$ — сколько в среднем неопределённости остаётся в X, если Y известен. Цепное правило: $H(X, Y) = H(Y) + H(X \mid Y)$.

2.3 Дивергенция Кульбака–Лейблера (KL)

$$\mathrm{KL}(P \,\|\, Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}.$$

Это мера того, насколько распределение Q «плохо заменяет» P. Свойства: $\mathrm{KL} \geq 0$ (неравенство Йенсена); $\mathrm{KL} = 0$ тогда и только тогда, когда $P = Q$; **несимметрична** ($\mathrm{KL}(P\|Q) \neq \mathrm{KL}(Q\|P)$), поэтому это не расстояние. Интуиция кодирования: $\mathrm{KL}(P\|Q)$ — лишние наты, которые вы платите, кодируя данные из P кодом, оптимизированным под Q.

Числа. $\mathrm{KL}(\mathrm{Bern}(0.9)\,\|\,\mathrm{Bern}(0.5)) = 0.9\ln(0.9/0.5) + 0.1\ln(0.1/0.5) = 0.368$ нат, а в обратную сторону $\mathrm{KL}(\mathrm{Bern}(0.5)\,\|\,\mathrm{Bern}(0.9)) = 0.511$ нат. Одна и та же пара распределений — разные числа: асимметрия в действии.

2.4 Взаимная информация

Три равносильных определения:

$$I(X;Y) = \mathrm{KL}\big(p(x,y)\,\|\,p(x)p(y)\big) = \mathbb{E}_{p(x,y)}\Big[\log\frac{p(x,y)}{p(x)p(y)}\Big] = H(X) - H(X\mid Y).$$

Словами последней формы: «насколько знание Y снижает неопределённость об X». Свойства: симметрична ($I(X;Y) = I(X;Y)(Y;X)$); неотрицательна; равна нулю *тогда и только тогда*, когда X и Y независимы; $H(X,Y) = H(X) + H(Y) - I(X;Y)$.

Числа: мороженое и погода. X — погода ($p(\text{солнце}) = 0.6$, $p(\text{дождь}) = 0.4$); Y — «съели мороженое» (при солнце да с вероятностью 0.9, при дожде — 0.25). Совместная таблица: $p(\text{солнце}, \text{да}) = 0.54$, $p(\text{солнце}, \text{нет}) = 0.06$, $p(\text{дождь}, \text{да}) = 0.10$, $p(\text{дождь}, \text{нет}) = 0.30$; маргиналы: $p(\text{да}) = 0.64$, $p(\text{нет}) = 0.36$. Считаем: $H(X) = 0.673$ нат, $H(Y) = 0.653$ нат, $H(X,Y) = 1.093$ нат, значит $I(X;Y) = H(X) + H(Y) - H(X,Y) = 0.233$ нат ≈ 0.337 бит. Погода и мороженое действительно «несут друг о друге информацию», но немного.

2.5 Гауссовский случай — наш рабочий эталон

Если (X,Y) — совместно гауссовские размерности d с $\mathrm{corr}(x_i, y_j) = \delta_{ij}\rho$ (каждая координата связана только со «своей», с коэффициентом ρ), то

$$I(X;Y) = -\frac{d}{2}\log(1-\rho^2). \tag{1}$$

Это *главная формула задания*: на такой симуляции истинная ВИ известна, и именно с ней сравнивают оценки. Полезно запомнить её поведение: при $\rho = 0$ получаем $I(X;Y) = 0$ (независимость); при $\rho \to 1$ ВИ уходит в бесконечность.

2.6 Инвариантность к биекциям

ВИ не меняется при взаимно-однозначных (биективных) преобразованиях аргументов: $I(X;Y)(f(X);g(Y)) = I(X;Y)(X;Y)$ для обратимых f, g. Доказательство в одну строку через формулу замены переменных: при $x' = f(x)$ плотность преобразуется как $p(x') = p(x)/|\det J_f(x)|$, и в отношении $p(x,y)/(p(x)p(y))$ якобианы сокращаются, а от отношения плотностей ВИ и зависит.

Зачем это в задании. Инвариантность — сильная проверка честности оценщика: если вы растянули Y преобразованием $y \mapsto \sinh(y)$, информация никуда не делась (преобразование обратимо!), и хороший оценщик должен вернуть то же число. Корреляция Пирсона такой тест проваливает — она меняется при нелинейной деформации.

2.7 «Что мы предсказываем» — главное против заблуждений

Это **не** классификация и **не** регрессия в привычном смысле. В классическом ML есть пары «вход → метка» и сеть предсказывает метку. Здесь **нет метки** «$I(X;Y) = 7.3$ ната». Сеть не учится выдавать число $I(X;Y)$.

Вместо этого сеть обучается представлять вспомогательный объект, из которого ВИ *вычисляется по формуле*:

- **MINE**: сеть-критик $T_\theta(x, y)$ учится приближать *логарифм отношения плотностей* $\log \frac{p(x,y)}{p(x)p(y)}$ — функцию «насколько пара похожа на настоящую». Оценка ВИ — это значение обучающего лосса.
- **CLUB**: сеть $q_\theta(y \mid x)$ учится приближать условную плотность $p(y \mid x)$ — это *обычная* задача: по x предсказывать y. Оценка ВИ — формула, в которую подставляют уже обученную, замороженную сеть.

Истинная формула (1) используется *только* для валидации (сравнить оценку с ответом), в лосс она не входит никогда.

Задача	Что предсказывает сеть	Таргет обучения	Где $I(X;Y)$
Классификация	класс	метка y	—
Регрессия	число	значение y	—
MINE	скор пары $T(x, y)$	неявный: $\log \frac{p(x,y)}{p(x)p(y)}$	= лосс
CLUB	распределение $q(y \mid x)$	настоящий y	формула после обучения

2.8 Как мерить качество оценки

Раз $I(X;Y)$ — это число, оценка $\hat{I}$ — тоже число, и её качество меряют как у любой оценки: **смещение** (bias) $\mathbb{E}[\hat{I}] - I(X;Y)$ и **дисперсия**. Для отчёта полезны: знак и величина смещения по сетке ρ, стандартное отклонение по нескольким сидам, RMSE относительно истинной кривой, и, конечно, *направление границы* ($\hat{I} \le I(X;Y)$ для MINE, $\hat{I} \ge I(X;Y)$ для CLUB).

2.9 Словарь терминов задания

Термин	Что значит
ВИ (MI)	взаимная информация $I(X;Y)$; мера зависимости; в задании считается в натах
Критик T_θ	сеть со скалярным выходом на паре (x, y), обучаемая в MINE
Положительные пары	(x_i, y_i) из совместного распределения — «настоящие» пары
Отрицательные пары	$(x_i, y_{\pi(i)})$: y перемешан в батче — пары «как будто независимые»
Перемешивание	сдвиг (shift) или случайная перестановка (`randperm`) индексов y в батче
Лог-сам-эксп	численно устойчивый способ считать $\log \mathbb{E}[e^T]$: logsumexp вместо exp
EMA	экспоненциальное скользящее среднее; в MINE — по отрицательному члену, чтобы убрать смещение градиента
Нат	единица информации при натуральном логарифме (1 нат $\approx$ 1.443 бит)
Коллапс $\sigma^2 \to 0$	вырождение дисперсии гауссианы в vCLUB, «взрывающее» оценку
$\mathcal{O}(N^2)$ / $\mathcal{O}(N)$	сложность полной/выборочной версии CLUB
Абляция	эксперимент с отключённым компонентом метода, показывающий его вклад
Биекция	обратимое взаимно-однозначное преобразование; ВИ при нём не меняется
Unlearning	удаление нежелательной информации из модели путём минимизации ВИ

3 Задача: что нужно сделать

3.1 Что дано и что требуется

Дано: выборка пар $\{(x_i, y_i)\}_{i=1}^N$ из неизвестного совместного распределения $p(x, y)$. Плотности недоступны. Требуется: оценить $I(X;Y)$ одним из двух нейросетевых оценщиков — **MINE** (нижняя оценка) или **CLUB** (верхняя), провалидировать на гауссовской симуляции с известным ответом и написать отчёт с абляциями. Это и есть всё задание.

3.2 MINE: нижняя оценка

Теоретическая основа. Двойственное представление Донскера–Варадхана:

$$\mathrm{KL}(\mathbb{P} \,\|\, \mathbb{Q}) = \sup_T \Big\{ \mathbb{E}_{\mathbb{P}}[T] - \log \mathbb{E}_{\mathbb{Q}}\big[e^T\big] \Big\}.$$

Почему это правда и почему оптимум — именно отношение плотностей? Для любой T определим «перевзвешенное» распределение R с плотностью $dR/dQ = e^T / \mathbb{E}_Q[e^T]$ (это просто нормировка). Тогда прямая подстановка даёт

$$\mathbb{E}_P[T] - \log \mathbb{E}_Q[e^T] = \mathrm{KL}(P\|Q) - \mathrm{KL}(P\|R) \;\le\; \mathrm{KL}(P\|Q),$$

и равенство достигается ровно когда $P = R$, то есть $e^T \propto dP/dQ$. Значит оптимальный критик — это

$$T^*(x, y) = \log \frac{p(x, y)}{p(x)p(y)} \quad \text{(плюс константа)},$$

а именно логарифм отношения совместной плотности к произведению маргинальных (точечная взаимная информация, PMI). Суть MINE: *сеть учится логарифму отношения плотностей, не зная самих плотностей*.

Как это считается на батче. При $\mathbb{P} = p(x, y)$, $\mathbb{Q} = p(x)p(y)$:

$$\hat{I}_{\mathrm{MINE}}(\theta) = \frac{1}{N} \sum_i T_\theta(x_i, y_i) - \log \Big(\frac{1}{N} \sum_i e^{T_\theta(x_i,\, y_{\pi(i)})} \Big) \;\le\; I(X;Y).$$

Первый член — средний скор *положительных* пар из совместного распределения. Второй — лог среднего экспоненты скоров *отрицательных* пар, полученных перемешиванием y в батче (сдвиг или `randperm`): если x и y перемешаны, это ровно выборка из $p(x)p(y)$.

Главный факт: лосс и есть оценка. Обучение MINE — это максимизация $\hat{I}_{\mathrm{MINE}}$ градиентным *подъёмом*. Нет отдельной фазы предсказания: после обучения $\hat{I}_{\mathrm{MINE}}$ — просто значение этого же функционала (на отложенных данных). Поэтому кривая обучения MINE одновременно является кривой оценки.

Что означает каждая рекомендация из задания.

1. *Критик с одним скалярным выходом.* Сеть принимает конкатенацию $[x, y]$ и выдаёт одно число — скор пары.
2. *Отрицательные пары перемешиванием y.* Независимые пары негде взять, их имитируют: перемешивание разрушает попарную связь, и x_i с чужим $y_{\pi(i)}$ распределены как $p(x)p(y)$.
3. *Лог-сам-эксп вместо* exp. e^T с растущим скором переполняет float. Численно устойчиво: $\log(\frac{1}{N}\sum e^{t_i}) = \mathrm{logsumexp}(t_1, \ldots, t_N) - \log N$. В коде: `torch.logsumexp(neg) - math.log(N)`.

4. *EMA по отрицательному члену.* Градиент $\log \mathbb{E}_Q[e^T]$ оценивается по мини-батчу с заметным смещением из-за экспоненциального перевзвешивания (пары с большим скором давят сильнее). Решение из статьи MINE: вести экспоненциальное скользящее среднее величины $\mathbb{E}_Q[e^T]$ и использовать его в знаменателе лосса.

Ожидаемое поведение. По построению $\hat{I}_{\text{MINE}} \le I(X;Y)$: оценка должна лежать *ниже* истинной кривой и приближаться к ней по мере обучения. Важно: нижняя оценка может быть *отрицательной* — это нормально (например, при $\rho = 0$ критик болтается около нуля, и оценка — около нуля с шумом в обе стороны). На конечной выборке возможен шум, в том числе небольшое превышение истины; систематическое превышение — признак переобучения критика.

3.3 CLUB: верхняя оценка

Определение. При *известной* условной плотности $p(y \mid x)$:

$$I_{\text{CLUB}} = \mathbb{E}_{p(x,y)}\big[\log p(y \mid x)\big] - \mathbb{E}_{p(x)}\mathbb{E}_{p(y)}\big[\log p(y \mid x)\big].$$

Почему это верхняя оценка? Добавим и вычтем $\mathbb{E}\log p(y)$ и соберём KL:

$$I_{\text{CLUB}} - I(X;Y) = \mathbb{E}_{p(x)p(y)}\Big[\log \frac{p(y)}{p(y \mid x)}\Big] = \mathbb{E}_{p(x)}\Big[\text{KL}\left(p(y) \,\|\, p(y \mid x)\right)\Big] \;\ge\; 0.$$

Итак, $I_{\text{CLUB}} = I(X;Y) + \mathbb{E}_{p(x)}\,\text{KL}(p(y) \,\|\, p(y \mid x))$: истинная ВИ плюс неотрицательный зазор. Равенство — только при независимости (тогда оба нули).

vCLUB: когда условная плотность неизвестна. $p(y \mid x)$ заменяют вариационным приближением — например, гауссианой $q_\theta(y \mid x) = \mathcal{N}(y;\ \mu_\theta(x),\ \sigma_\theta^2(x) \cdot I)$, где среднее и дисперсию выдаёт сеть. Подставляя q_θ в ту же формулу, получают vCLUB. Сеть учат *отдельно*, обычным максимумом правдоподобия: $\frac{1}{N}\sum_i \log q_\theta(y_i \mid x_i) \to \max$ (для гауссианы это фактически MSE с обучаемой дисперсией). Потом сеть замораживают и считают оценку:

$$\hat{I}_{\text{vCLUB}} = \frac{1}{N}\sum_i \log q_\theta(y_i \mid x_i) - \frac{1}{N^2}\sum_{i,j} \log q_\theta(y_j \mid x_i).$$

Первый член — насколько правдоподобен *настоящий* y при данном x; второй — насколько правдоподобен *случайный* y; разница и есть «информативность пары». Важно: vCLUB остаётся верхней оценкой, только если q_θ хорошо приближает $p(y \mid x)$; при плохом приближении гарантия пропадает.

Число для самопроверки (важно!). В гауссовской постановке задания $p(y \mid x) = \mathcal{N}(\rho x,\ (1-\rho^2)I)$ — то есть условная плотность *сама* гауссова, и сеть может выучить её точно. Если $q_\theta = p(y \mid x)$, то $I_{\text{CLUB}} = d\rho^2/(1-\rho^2)$. Это *больше* истинной ВИ из (1): например, $d = 1$, $\rho = 0.8$ даёт $I_{\text{CLUB}} = 1.78$ нат против $I(X;Y) = 0.51$ нат. Вывод: vCLUB в этой постановке — *не точная* оценка, а честная верхняя граница с ненулевым зазором, и её значение $d\rho^2/(1-\rho^2)$ можно предсказать заранее. Если ваша vCLUB-оценка близка к этому числу — сеть выучилась хорошо; если она ещё выше — что-то не так (обычно коллапс σ^2).

Что означает каждая рекомендация из задания.

1. *Учить только на лог-правдоподобии.* Если дифференцировать полную оценку, градиент потечёт через двойную сумму $\mathcal{O}(N^2)$ — медленно и шумно, а главное — сеть начнёт «оптимизировать под оценку», ломая приближение. Правильно: фаза 1 — обычная регрессия $y \mid x$ (MLE), фаза 2 — заморозить и посчитать оценку без градиентов.

2. *Выборочная версия* $\mathcal{O}(N)$. Второй член можно оценивать не по всем N^2 парам, а по N парам $(x_i, y_{j(i)})$ со случайным $j(i)$: получится несмещённая оценка того же выражения ценой чуть большей дисперсии.
3. *Коллапс* $\sigma^2 \to 0$. При переобучении сеть уменьшает дисперсию: $\log q_\theta(y \mid x) = -\frac{d}{2}\log(2\pi\sigma^2) - \frac{\|y-\mu\|^2}{2\sigma^2}$, и при $\sigma^2 \to 0$ первый член уходит в $+\infty$ — оценка «взрывается» вверх. Лечение: параметризовать $\log\sigma^2$ вместо σ^2, клиппинг $\sigma^2 \geq \sigma^2_{\min}$, общая (не зависящая от x) дисперсия, early stopping.

3.4 Таргеты: сводка «кто что учит»

	MINE	CLUB (vCLUB)
Сеть	критик $T_\theta(x, y) \to \mathbb{R}$	$q_\theta(y \mid x)$: гауссиана с $\mu_\theta, \sigma^2_\theta$
Таргет обучения	нет явного; неявный — $\log \frac{p(x,y)}{p(x)p(y)}$	настоящий y
Лосс	$\hat{I}_{\text{MINE}}$ (максимизация)	$-\frac{1}{N}\sum \log q_\theta(y_i \mid x_i)$ (NLL)
Когда читают оценку	значение лосса (обучение = оценивание)	после обучения, формулой по замороженной сети
Направление	$\hat{I} \leq I(X;Y)$ (нижняя)	$\hat{I} \geq I(X;Y)$ при хорошем q (верхняя)
Истинная $I(X;Y)$ в лоссе	нет	нет

Повторим главное: **ни в одном методе сеть не учится предсказывать число** $I(X;Y)$. Истинная ВИ из формулы (1) — внешний «учитель», который появляется только при валидации, чтобы сверить ответ.

3.5 Валидация по заданию

Генератор. (X, Y) — многомерное гауссово размерности d с $\text{corr}(x_i, y_j) = \delta_{ij}\rho$: генерируем $x \sim \mathcal{N}(0, I)$ и $y = \rho x + \sqrt{1-\rho^2}\,\varepsilon$, где $\varepsilon \sim \mathcal{N}(0, I)$ независимо. Истинное значение — формула (1). Меняя ρ, получаем сетку значений $I(X;Y)$ в диапазоне 2–10 нат.

Как выбрать d и ρ. При $d = 1$ даже $\rho = 0.99$ даёт всего ≈ 2.6 нат, поэтому удобно брать $d = 10$ и сетку, например:

ρ	0.45	0.55	0.65	0.75	0.82	0.92
$I(X;Y)$, наты ($d = 10$)	1.13	1.80	2.75	4.13	5.58	9.37

Три обязательные проверки.
1. *Направление границы*: MINE должен давать $\hat{I} \leq I(X;Y)$, CLUB — $\hat{I} \geq I(X;Y)$, по всей сетке ρ.
2. *Независимость*: при $\rho = 0$ оценка должна быть ≈ 0. Толкование «$\approx$»: в пределах шума (MINE может быть отрицательным, у классических оценщиков вроде KSG остаётся небольшой конечновыборочный шум) — главное, что оценка на порядки меньше, чем при $\rho > 0$.
3. *Инвариантность*: применить биекции (например, $y \mapsto \sinh(y)$ покомпонентно или обратимое линейное $x \mapsto Ax$) — оценка должна остаться той же. Ловушка для CLUB: после нелинейной биекции данные перестают быть гауссовыми, и гауссова q_θ приближает $p(y' \mid x)$ хуже — оценка деградирует, это стоит обсудить в отчёте как ограничение.

Ловушки, которые проверяющий увидит (или не увидит) сразу.
- MINE-оценка может быть отрицательной — это нормально, в отчёте так и напишите.
- Переобученный критик систематически завышает MINE — держите оценку на отложенной выборке.

- Для MINE важен размер батча: отрицательные пары берутся из батча, и качество границы зависит от него — это готовая абляция.
- Несколько сидов и полосы ±std на всех графиках — иначе «результат» не считается воспроизводимым.
- Гиперпараметры (скорость, ширина сети, число шагов) — явно в отчёте.

3.6 Что сдавать и как оценивают

Критерий отбора из задания: *правильная реализация, подробный отчёт, абляционные эксперименты*. Минимальный состав сдачи: код (генератор + оценщик + скрипты валидации), график $\hat{I}$ против истинной кривой с полосами по сидам, три проверки выше, 2–3 абляции (например: log-sum-exp вкл/выкл, EMA вкл/выкл, сдвиг vs `randperm`, архитектура критика — линейная vs MLP; для CLUB: полная vs выборочная версия, клиппинг σ^2, гауссова q на не-гауссовых данных), и текст отчёта. *Совет: один метод, сделанный честно и до конца, сильнее двух недоделанных.* CLUB надёжнее (обычная регрессия + формула, и вы заранее знаете, к какому числу должна сойтись оценка); MINE эффектнее (нижняя граница с EMA), но капризнее.

4 Бейзлайн: потрогать числа руками

4.1 Зачем бейзлайн

Прежде чем писать нейросетевой оценщик, полезно увидеть саму величину: сгенерировать данные, посчитать истинную ВИ по формуле (1), оценить её классическими методами и посмотреть на числа и графики. Файл `00_baseline_colab.py` делает ровно это без единой нейросети (numpy + scipy + matplotlib, всё есть в Colab). Запуск в Colab:

```
exec(open('00_baseline_colab.py', encoding='utf-8').read())
```

4.2 Что внутри файла

1. **Генератор** `sample_gauss(d, rho, n)` — ровно модель из задания: $y = \rho x + \sqrt{1-\rho^2}\,\varepsilon$.
2. **Истинная ВИ** `true_mi(d, rho)` — формула (1).
3. **Оценка №1: гистограммная** (`mi_hist`, только $d = 1$). Простейшая идея: нарезать x и y на бины, оценить частоты $p(x, y)$, $p(x)$, $p(y)$ и подставить в определение ВИ. Преподаёт два урока: (а) оценка смещена — при малом N и многих бинах завышает, при мало бинов — занижает; (б) клеток B^{2d} — проклятие размерности, поэтому только $d = 1$.
4. **Оценка №2: KSG** (`mi_ksg`, kNN-оценка Кржижанова–Штёгбауэра–Грассбергера). Классический непараметрический оценщик: для каждой точки ищут расстояние до k-го соседа в совместном пространстве, считают соседей в маргинальных, и комбинируют через дигамма-функцию. Необязателен для задания, но это отличная «эталонная линия» для отчёта.
5. **График 1**: KSG против истинной кривой по сетке ρ — должны почти совпасть (с полосами по сидам).
6. **График 2** (тест независимости): $\rho = 0$, гистограмма оценок по 30 сидам — должны скучиться около нуля.
7. **График 3** (инвариантность): $y \mapsto \sinh(y)$ покомпонентно — KSG должен вернуть то же значение, а корреляция Пирсона изменится. Числа печатаются в консоль.
8. **График 4** (нелинейная зависимость): $y = x + \varepsilon$ против $y = x^2 + \varepsilon$ — корреляция во втором случае около нуля, а ВИ заметно больше нуля. Наглядная демонстрация, зачем вообще ВИ.

4.3 Чеклист понимания после прогона

Если вы можете ответить на пять вопросов — можно переходить к нейросетям. (1) Почему кривая $I(X;Y)(\rho)$ растёт и уходит в бесконечность при $\rho \to 1$? (2) Почему гистограммная оценка завышает

при большом числе бинов? (3) Почему KSG при $\rho = 0$ даёт не ровно ноль, а значение с небольшим шумом вокруг нуля? (4) Почему после sinh корреляция изменилась, а ВИ — нет? (5) Почему ВИ видит зависимость $y = x^2$, а корреляция — нет?

4.4 Следующий шаг: минимальный MINE

Файл `01_mine_minimal.py` — минимальный рабочий MINE на PyTorch (в Colab уже установлен): критик-MLP на конкатенации $[x, y]$, лосс с `logsumexp` и $\log N$, перемешивание через `randperm`, EMA-опция, обучение 400 шагов, оценка на отложенной выборке, график $\hat{I}$ против истинной кривой и кривая обучения. В файле есть два переключателя-абляции: `use_ema` (вкл/выкл EMA) и замена MLP на линейный критик $w \cdot (x^\top y)$ — запустите оба варианта и посмотрите, как линейный критик систематически занижает оценку (он не может представить оптимальный T^*, который в гауссовском случае является квадратичной формой). Это готовый прототип для настоящей реализации: добавьте сиды, сетку ρ под 2–10 нат ($d = 10$), проверку инвариантности и абляции.

4.5 Ещё один шаг: минимальный CLUB

Файл `02_club_minimal.py` — минимальный рабочий CLUB: сеть $q_\theta(y \mid x)$ в виде диагональной гауссианы (сеть выдаёт μ и $\log \sigma^2$, отсюда идёт клиппинг от коллапса $\sigma^2 \to 0$), фаза 1 — обычный MLE по совместным парам, фаза 2 — оценка по замороженной сети с переключателем «полная $\mathcal{O}(N^2)$ / выборочная $\mathcal{O}(N)$». На графике рядом с истинной кривой нарисована *предсказанная* граница $d\rho^2/(1-\rho^2)$ — если обученная vCLUB близка к ней, значит q выучена хорошо; если ниже истинной ВИ — q недоучена, и гарантия верхней оценки теряется. Рекомендация: если времени мало, в качестве основного метода сдавайте CLUB (проверяемо и устойчиво), а MINE оставьте для сравнения в отчёте.

5 План до 10 ноября

Ниже — реалистичный разрез по дням (итого 12–15 часов). Принцип приоритетов: сначала *корректность метода и направление границы*, потом три проверки, потом абляции, в самом конце — полировка отчёта. Если время жмёт, режьте снизу списка (сначала число абляций), но никогда не жертвуйте корректностью метода.

День	Что делать	Бюджет
Вс 8.11	**Понять и пощупать.** Прочитать лонгрид (§1–2) + «Visual Information Theory» К. Олаха для интуиции; перечитать §3 и исходный PDF задания; запустить `00_baseline_colab.py` в Colab, покрутить d, ρ, N, бины, k и закрыть чеклист из §4.3; выбрать метод (рекомендация: CLUB — надёжнее) и запустить `02_club_minimal.py`, сверив оценку с предсказанной линией $d\rho^2/(1-\rho^2)$	2–3 ч
Пн 9.11	**Сделать по-настоящему.** Довести оценщик до требований задания: log-sum-exp и EMA (MINE) или $\log \sigma^2$-параметризация + клиппинг и выборочная $\mathcal{O}(N)$-версия (CLUB); сетка ρ под 2–10 нат ($d = 10$); 3–5 сидов; оценка на отложенных данных. Провести три проверки валидации с графиками. Сделать 2–3 абляции из списка §3.6	5–6 ч
Вт 10.11	**Отчёт и сдача.** Написать отчёт (постановка → метод → протокол → результаты → абляции → выводы), вставить графики с полосами по сидам, таблицу гиперпараметров. Финальный прогон всего с нуля (проверка воспроизводимости), контроль направлений границ и $\rho = 0$, упаковка и отправка	3–4 ч

5.1 С чего начать изучение темы

1. Этот лонгрид, разделы 1–2 — термины и интуиция (45 мин).
2. Chris Olah, «Visual Information Theory» (colah.github.io) — картинки про энтропию, KL и ВИ (20 мин).
3. Раздел 3 + исходный PDF задания — постановка и ловушки (30 мин).
4. Бейзлайн `00_baseline_colab.py` — числа руками (1 ч).
5. Статья выбранного метода, только введение и формулы, без доказательств: MINE — arXiv:1801.04062 (§1–3); CLUB — arXiv:2006.12013 (§1–3) (30–40 мин).
6. Реализация (файлы-стартеры) и валидация — остальное время.

Резюме для тех, кто читает по диагонали. Задание — оценить взаимную информацию пары случайных величин по выборке без плотностей. Сеть не предсказывает число ВИ: MINE учит критика — логарифм отношения плотностей, и его лосс *является* нижней оценкой; CLUB учит обычную регрессию $q(y \mid x)$, а верхнюю оценку считают формулой по замороженной сети. Валидация — гауссовская симуляция с известным ответом $-\frac{d}{2}\log(1-\rho^2)$: проверить направление границы, нулевую оценку при независимости и инвариантность к биекциям. Сдать: код, отчёт, абляции. До 10-го реально успеть, если начать сегодня с раздела 4.
