Нижняя оценка взаимной информации: метод MINE

Борисов Никита · 2 курс, трек ML · n.borisov@edu.centraluniversity.ru · Москва, 2026

Взаимная информация (ВИ) измеряет статистическую зависимость двух случайных величин и, в отличие от корреляции, видит и нелинейные связи: для $Y = X^2$ корреляция равна нулю, а информация о связи — нет. В работе рассмотрены три способа оценить ВИ по выборке: гистограммный (Binning), kNN-оценщик (KSG) и нейросетевой MINE. Основным выбран MINE — он даёт *нижнюю* оценку и позволяет максимизировать ВИ; его «зеркало», верхняя оценка CLUB, нужна для минимизации и в этой части не рассматривается.

Краткий план

- Метрики: что такое взаимная информация
- Постановка: гауссовская модель с известным ответом
- Методы: Binning, KSG, MINE
- Бейзлайны на малой размерности
- MINE: сравнение и валидация

1. МЕТРИКИ

Взаимная информация — это дивергенция Кульбака–Лейблера между совместным распределением и произведением маргинальных:

$$I(X;Y) = D_{\mathrm{KL}}\big(p(x,y)\,\|\,p(x)p(y)\big) = \mathbb{E}_{p(x,y)}\left[\log \frac{p(x,y)}{p(x)p(y)}\right]. \tag{1}$$

Свойства, на которых держится вся дальнейшая проверка: $I \geq 0$; $I = 0$ тогда и только тогда, когда X и Y независимы; I симметрична; и I не меняется при обратимых преобразованиях данных — $I(f(X); g(Y)) = I(X;Y)$ для биекций f, g, потому что якобианы сокращаются в отношении плотностей.

Точный расчёт (1) требует плотностей, которых на практике нет: есть только выборка пар $\{(x_i, y_i)\}_{i=1}^{N}$. Поэтому ВИ оценивают, а «правильность» оценки проверяют по направлению границы: нижняя оценка должна лежать ниже истины, верхняя — выше.

2. ПОСТАНОВКА ЗАДАЧИ

Проверка идёт на синтетике, где истинный ответ известен. Берём (X, Y) совместно гауссовскими размерности d:

$$x \sim \mathcal{N}(0, I_d), \qquad y = \rho\, x + \sqrt{1-\rho^2}\,\varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, I_d), \tag{2}$$

где ε не зависит от x. Тогда $\mathrm{corr}(x_i, y_j) = \delta_{ij}\rho$: каждая координата y_i связана только со «своей» x_i с одним и тем же коэффициентом ρ, а между разными координатами корреляция нулевая. Для этой модели

$$I(X;Y) = -\frac{d}{2}\,\log\!\big(1-\rho^2\big), \tag{3}$$

и при $\rho = 0$ получаем $I = 0$ (независимость), а при $\rho \to 1$ — расходимость.

В основной серии $d = 10$, а сетка — 30 точек $\rho \in [0.1, 0.99]$; она даёт $I \approx 0.05 \dots 19.6$ нат, причём заявленный в задании диапазон 2–10 нат покрывается её частью ($\rho \approx 0.59 \dots 0.93$). Качество оценки измеряем направлением границы ($\hat{I} \le I$ для MINE), смещением $\hat{I} - I$ и разбросом по сидам.

3. МЕТОДЫ

3.1 Binning

Идея — самая прямая: разложить обе величины по бинам и посчитать частоты. Бины удобно брать по квантилям, чтобы клетки получались равновероятными; тогда по нормированной совместной гистограмме получаются оценки $\hat{p}_{xy}$, $\hat{p}_x$, $\hat{p}_y$, и остаётся подставить их в определение (1):

$$\hat{I}_{\text{bin}} = \sum_{i,j} \hat{p}_{xy}[i,j] \, \log \frac{\hat{p}_{xy}[i,j]}{\hat{p}_x[i]\,\hat{p}_y[j]}. \tag{4}$$

Метод не требует обучения и легко интерпретируется, но у него две беды: смещение (при малом N и многих бинах он завышает, при малом числе бинов — занижает) и проклятие размерности: клеток B^{2d}, поэтому он применим только при малых d.

3.2 KSG

KSG не строит сетку, а адаптируется к локальной плотности: для каждой точки ищутся k ближайших соседей, и плотность оценивается по расстояниям до них (оценка энтропии Козаченко–Леоненко). Оценщик ВИ — это комбинация трёх таких оценок — совместной и двух маргинальных; трюк в том, что один и тот же радиус ε берётся из совместного пространства и переиспользуется в маргиналах, поэтому расстояния сокращаются, и остаются только счётчики соседей:

$$\hat{I}_{\text{KSG}} = \psi(k) + \psi(N) - \frac{1}{N} \sum_{i} \Big[\psi\big(n_x(i) + 1\big) + \psi\big(n_y(i) + 1\big) \Big], \tag{5}$$

где $n_x(i)$ — число точек в x-шаре радиуса ε_i, $n_y(i)$ — то же по y, а ψ — дигамма-функция, возникающая из kNN-оценки энтропии. Вывод и свойства — в оригинальной работе [2]; для дальнейшего важно только, что оценка строится по счётчикам соседей, не требует плотностей и не имеет бинов.

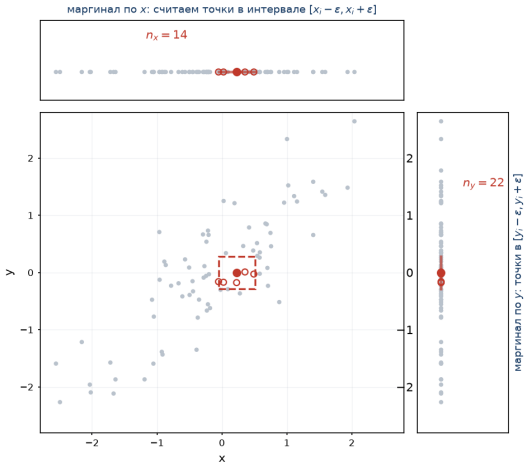


Рис. 1: Устройство KSG: радиус ε до k-го соседа в совместном пространстве и счётчики n_x, n_y в маргиналах.

3.3 MINE

MINE опирается на двойственное представление Донскера–Варадхана:

$$D_{\mathrm{KL}}(P\|Q) = \sup_{T} \Big\{ \mathbb{E}_P[T] - \log \mathbb{E}_Q\big[e^T\big] \Big\}. \tag{6}$$

При $P = p(x,y)$, $Q = p(x)p(y)$ и критике T_θ, который параметризует сеть:

$$I(X;Y) \;\geq\; \hat{I}_{\mathrm{MINE}}(\theta) = \mathbb{E}_{p(x,y)}[T_\theta] - \log \mathbb{E}_{p(x)p(y)}\big[e^{T_\theta}\big]. \tag{7}$$

Равенство достигается при $T^*(x,y) = \log \frac{p(x,y)}{p(x)p(y)}$ — сеть учит логарифм отношения плотностей, не зная самих плотностей. На батче:

$$\hat{I}_{\mathrm{MINE}} = \frac{1}{N}\sum_{i=1}^{N} T_\theta(x_i, y_i) - \log\Big(\frac{1}{N}\sum_{i=1}^{N} e^{T_\theta(x_i,\, y_{\pi(i)})}\Big), \tag{8}$$

где положительные пары (x_i, y_i) берутся из совместного распределения, а отрицательные получаются перемешиванием y в батче (случайная перестановка индексов): перемешанная пара распределена как $p(x)p(y)$. Второй член считается через `logsumexp` (иначе e^T переполняет float), а среднее $\mathbb{E}_Q[e^T]$ оценивается по мини-батчу с экспоненциальным скользящим средним — это убирает смещение градиента $\log \mathbb{E}_Q[e^T]$.

Интуиция. Оценка $\hat{I}_{\mathrm{MINE}}$ — это ещё и лосс из двух частей: (1) скор положительных пар — модель учится «выуживать» максимум информации из настоящих пар; (2) минус скор отрицательных пар — та же модель не должна выдавать информации о перемешанных парах, ведь связи между ними нет. Поэтому при независимых величинах скор получается нулевым: перемешанные пары дают такой же скор, как настоящие. Решаем задачу *градиентного подъёма*, поскольку MINE — нижняя оценка на I (в коде лосс берётся со знаком минус, так как оптимизатор минимизирует).

Почему критик должен быть квадратичным. В гауссовской модели

$$T^*(x,y) = \frac{\rho}{1-\rho^2}\,(x \cdot y) - \frac{\rho^2}{2(1-\rho^2)}\big(\|x\|^2 + \|y\|^2\big) + \text{const}, \tag{9}$$

то есть *квадратичная форма* по паре (x,y): к билинейному члену добавляются $\|x\|^2$ и $\|y\|^2$. Линейная (билинейная) модель $T = w\,(x \cdot y)$ их не воспроизводит — у неё другая геометрия линий уровня. Поэтому одна из абляций — *линейный* критик: он нужен как контроль, показывающий, что метод ограничен не формулой, а ёмкостью приближения логарифма отношения плотностей.

4. БЕЙЗЛАЙНЫ НА МАЛОЙ РАЗМЕРНОСТИ

При $d = 1$ оба классических оценщика информативны, и их различие хорошо видно на схеме ниже: Binning кладёт данные в фиксированную сетку, и точность ограничена размером клетки; KSG строит окрестность вокруг каждой точки, поэтому локальная структура данных используется напрямую.

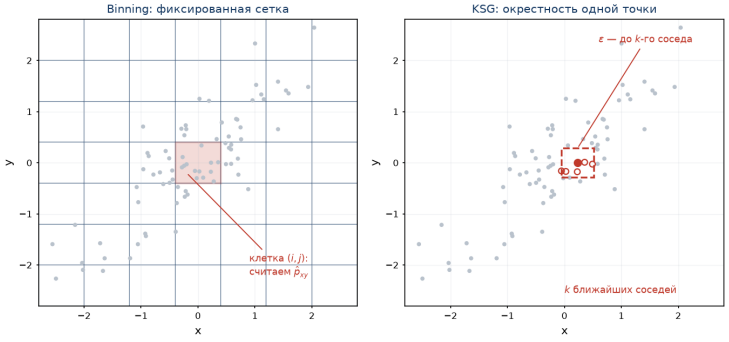


Рис. 2: Абстрактное различие: фиксированная сетка (Binning) против адаптивной окрестности точки (KSG).

На практике KSG практически совпадает с истинной кривой, а биннинг систематически смещён: гистограмма «теряет» разрешение при фиксированном числе бинов, тогда как kNN адаптируется к плотности. При росте размерности биннинг умирает быстрее: клеток B^{2d}, и чтобы в каждой было достаточно точек, нужно экспоненциально много данных. KSG страдает от разреженности мягче, но в высокой размерности и он проседает (см. раздел 5): соседей в шаре становится мало, и оценка систематически занижается.

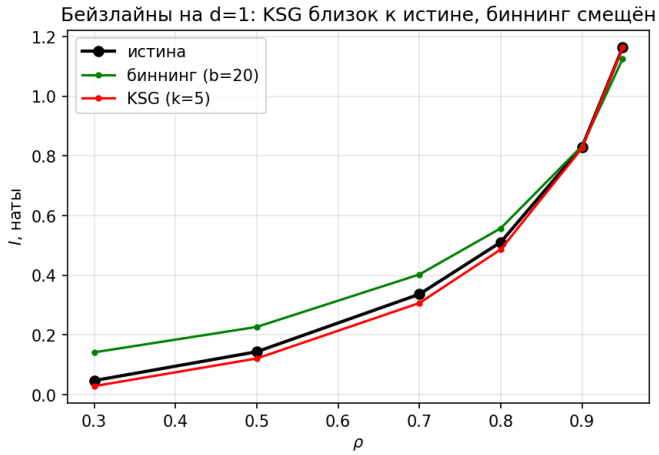


Рис. 3: Бейзлайны при $d = 1$: истина, гистограммная оценка ($B = 20$) и KSG ($k = 5$).

5. ЭКСПЕРИМЕНТЫ: MINE

Экспериментальная часть разбита на пять шагов: (1) основная сетка ρ; (2) поле критика; (3) тест независимости; (4) инвариантность к биекциям; (5) абляции. Ниже — по одному подразделу на каждый шаг.

Модель: $d = 10$, сетка ρ — 30 точек от 0.1 до 0.99, батч 512, 500 шагов Adam с $\eta = 10^{-3}$, критик $2d \to 64 \to 64 \to 1$ (ELU); оценка считается на отложенной выборке, а не на обучающей. Полный список гиперпараметров — в табл. 1.

Таблица 1: Гиперпараметры экспериментов. Сиды: 3 — в основной серии, 5 — в абляциях 4–5, 100 — в тесте независимости.

Параметр	Значение	Параметр	Значение
Размерность d	10	Критик	MLP $2d \to 64 \to 64 \to 1$ (ELU)
Сетка ρ	30 точек, $0.1 \dots 0.99$	Оптимизатор	Adam, $\eta = 10^{-3}$
N_{train} / N_{eval}	8192 / 4096	Шагов / батч	500 / 512
EMA, β	0.01	Отрицательные пары	randperm (shift в абляции)
Оценка $\hat{I}$	8 батчей $\times$ 512	Данные	$y = \rho x + \sqrt{1-\rho^2}\,\varepsilon$

5.1 Основная валидация на сетке ρ

Результаты — в табл. 2 и на рис. 4.

Таблица 2: Оценка MINE на части сетки ρ, покрывающей 2–10 нат ($d = 10$, 3 сида), и сравнение с KSG.

ρ	I_{true}, нат	$\hat{I}_{\text{MINE}}$, нат	std	$\hat{I}_{\text{KSG}}$, нат
0.59	2.149	1.848	0.030	0.768
0.65	2.773	2.048	0.329	0.973
0.71	3.562	2.324	0.455	1.221
0.74	4.040	1.719	1.670	1.369
0.81	5.241	3.497	0.385	1.732
0.90	8.207	4.250	0.403	2.485
0.93	9.915	4.214	0.404	2.843

Во всех точках $\hat{I}_{\text{MINE}} \leq I$ — направление нижней границы соблюдается. Зазор растёт с ρ: 0.3 нат при $\rho = 0.59$, 5.7 нат при $\rho = 0.93$ и до 14.5 нат на правом краю полной сетки ($\rho = 0.99$). Причина — конечная ёмкость: чем сильнее связь, тем «круче» оптимальный критик (9), и тем труднее сети фиксированного размера его приблизить. Отдельно отметим точку $\rho = 0.74$: там один из трёх сидов не сошёлся (std 1.67), что видно по большой полосе ошибки, — единичный провал обучения, а не систематическая ошибка. KSG при $d = 10$ проседает ещё сильнее (до 4.2 нат при истине 19.6), что иллюстрирует слабость kNN в высокой размерности и мотивирует нейросетевые оценщики.

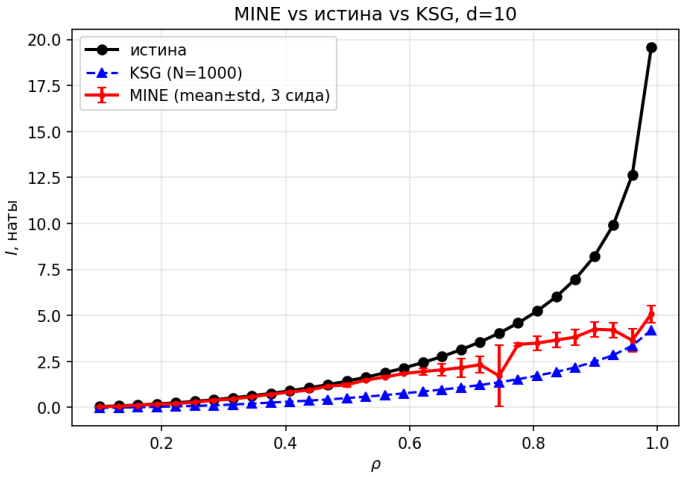


Рис. 4: MINE (mean $\pm$ std по 3 сидам) против истинной кривой и KSG при $d = 10$.

Направление границы удобно проверить напрямую: отложим оценку против истины — все точки должны лежать ниже диагонали $\hat{I} = I$. На требуемом диапазоне 2–10 нат это выполняется во всех точках (рис. 5).

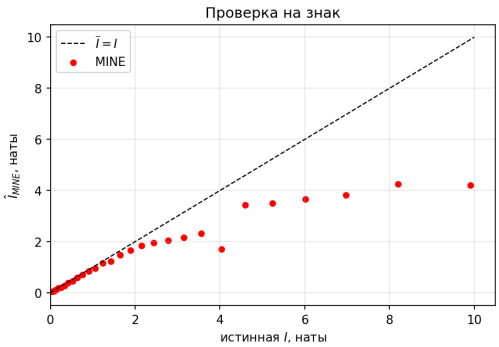


Рис. 5: Проверка на знак: оценка MINE против истинной ВИ. Все точки лежат ниже диагонали $\hat{I} = I$, то есть нижняя граница соблюдается.

5.2 Поле критика: чему учится сеть

Чтобы увидеть, *что именно* учит сеть, зафиксируем $d = 1$: тогда критик принимает пару $(x, y) \in \mathbb{R}^2$, и его можно нарисовать как тепловую карту. Истинный T^* — седло, повёрнутое на $45°$ (вдоль диагонали «есть связь»), а линейный критик даёт седло, выровненное по осям: именно этим он и не дотягивает. Числа в подписях: линейный $\hat{I} = 0.27$, MLP — 0.51 при истине 0.51 нат. Это и есть визуальное объяснение линейной абляции.

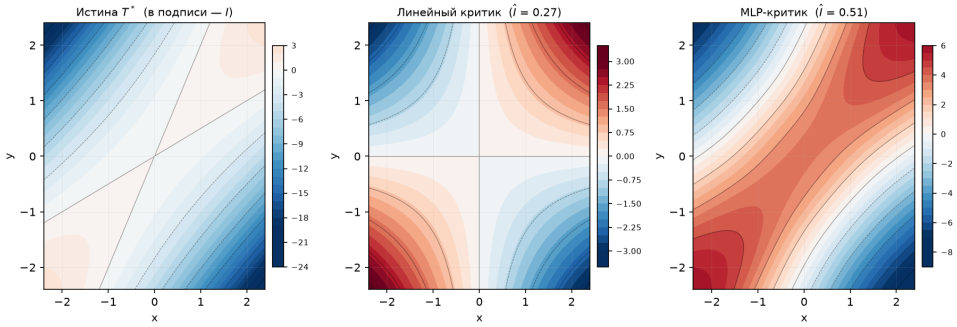


Рис. 6: Поле критика при $d = 1$, $\rho = 0.8$: истина T^* (квадратичная форма) и две модели. Линейный критик воспроизводит только «осевое» седло и теряет почти половину оценки; MLP выучивает T^* практически точно. Цветовые шкалы панелей независимы, значения $\hat{I}$ — в заголовках.

5.3 Тест независимости

При $\rho = 0$ оценка должна быть близка к нулю; по 100 сидам получено $\hat{I}_{\text{MINE}} = -0.0160 \pm 0.0051$ нат при истине $I = 0$. Небольшое отрицательное смещение — нормальное поведение нижней границы: оценка неотличима от нуля, а распределение по сидам показано на рисунке.

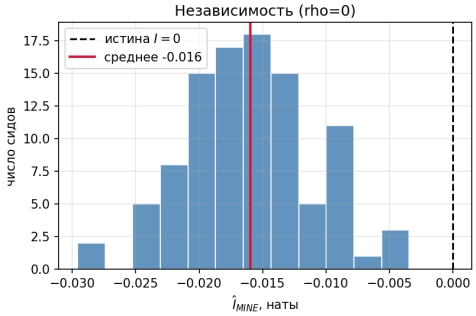


Рис. 7: Распределение оценок при $\rho = 0$ (100 сидов): среднее -0.015 нат, разброс ± 0.005.

5.4 Инвариантность к биекциям

При $d = 3$, $\rho = 0.8$ проверены две биекции: нелинейная $y \mapsto \sinh y$ и линейная $y \mapsto yA$ (обратимая матрица 3×3). Оценка на преобразованных данных совпадает с оценкой на исходных в пределах разброса, тогда как корреляция при деформации меняется: оценщик измеряет зависимость, а не линейную связь.

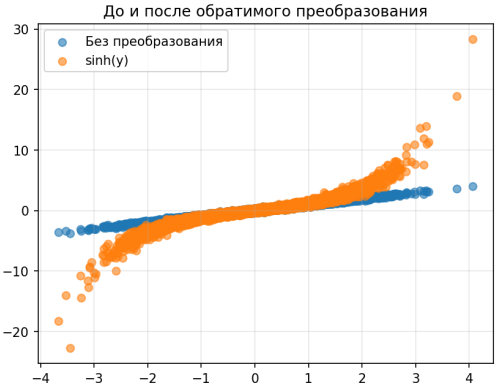


Рис. 8: Облако точек до и после $y \mapsto \sinh y$ ($d = 1$, $\rho = 0.99$): форма меняется, информация о связи — нет.

Таблица 3: Инвариантность к биекциям ($d = 3$, $\rho = 0.8$).

Метод	$\hat{I}$, нат
Истина	1.532
MINE(x, y)	1.511
MINE$(x, \sinh y)$	1.347
MINE(x, yA)	1.533

5.5 Абляционные эксперименты

Проведено пять абляций: (1) архитектура критика, (2) EMA, (3) способ получения отрицательных пар, (4) размер батча, (5) ширина сети. Все — при $\rho = 0.75$, $d = 10$ (истина 4.133 нат), и каждое значение — среднее по 5 запускам (разным сидам), чтобы убрать разброс между ними.

Абляции 1–3 (таблицы 4–6)

Абляция 1 — архитектура критика. Линейный критик $T = w\,(x \cdot y)$ не может воспроизвести квадратичный оптимум (9), поэтому заметно занижает оценку: MLP выигрывает около 0.7 ната (таблица 4).

Абляция 2 — EMA. Отключение EMA меняет оценку примерно на 0.5 ната, то есть в пределах разброса между сидами: EMA влияет на стабильность градиента, а не на систематическое смещение (таблица 5).

Абляция 3 — отрицательные пары. Случайная перестановка и циклический сдвиг дают практически одинаковый результат (таблица 6).

Таблица 4: Абляция 1 — архитектура критика

Критик	$\hat{I}$, нат
Истина	4.133
MLP	3.087
Линейный	2.354

Таблица 5: Абляция 2 — EMA

Вариант	$\hat{I}$, нат
Истина	4.133
EMA	2.999
Без EMA	3.533

Таблица 6: Абляция 3 — отрицательные пары

Вариант	$\hat{I}$, нат
Истина	4.133
randperm	3.061
shift	2.930

Абляции 4–5 (рисунок 9)

Абляция 4 — размер батча. С ростом батча оценка растёт: отрицательные пары берутся из батча, и

больший батч точнее аппроксимирует $p(x)p(y)$; при очень малых батчах критик просто не успевает обучиться за отведённые шаги.

Абляция 5 — ширина сети. Более широкая сеть лучше приближает оптимальный критик, но после ≈ 64 нейронов оценка выходит на плато: узкое место — не ёмкость модели, а бюджет обучения (500 шагов при $\eta = 10^{-3}$).

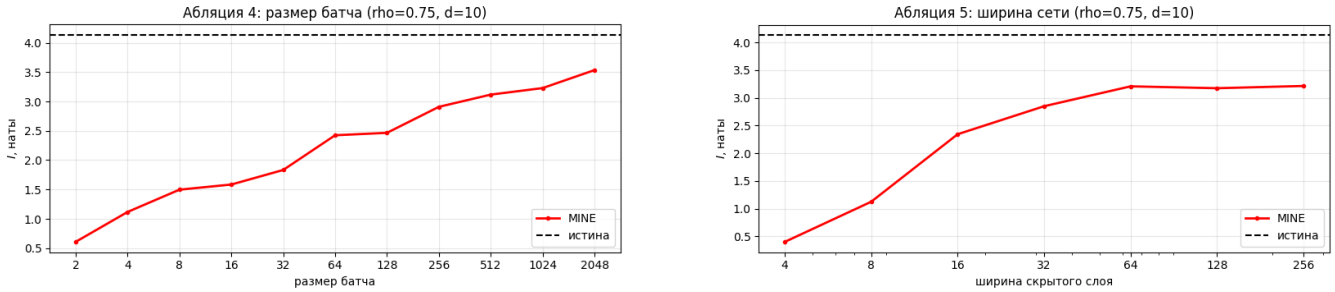


Рис. 9: Абляции 4–5: размер батча (слева) и ширина сети (справа). Все точки — среднее по 5 запускам; пунктир — истинное значение 4.133 нат.

Итоги. MINE корректно даёт нижнюю оценку на всём диапазоне $0.05 \ldots 19.6$ нат (включая требуемые 2–10), обращается в ноль при независимости и инвариантен к биекциям. Качество ограничено ёмкостью критика (линейный критик недобирает ≈ 1.8 ната относительно истины, поле критика это показывает напрямую) и параметрами обучения (батч, ширина сети). Бейзлайны работоспособны лишь в малой размерности. Задание требовало выбрать и реализовать один из двух оценщиков — реализован MINE; верхняя граница CLUB остаётся альтернативой для задач, где ВИ нужно минимизировать.

ЛИТЕРАТУРА

[1] Belghazi M. I., Baratin A., Rajeswar S., et al. MINE: Mutual Information Neural Estimation // ICML. 2018. arXiv:1801.04062.

[2] Kraskov A., Stögbauer H., Grassberger P. Estimating mutual information // Physical Review E. 2004. Vol. 69. 066138.

[3] Cheng P., Hao W., Dai S., et al. CLUB: A Contrastive Log-ratio Upper Bound of Mutual Information // ICML. 2020. arXiv:2006.12013.

[4] Cover T. M., Thomas J. A. Elements of Information Theory. 2nd ed. Wiley, 2006.