Вариационные оценки

Постановка

Взаимная информация (ВИ) случайных величин X, Y равна дивергенции Кульбака-Лейблера совместного распределения и произведения маргинальных распределений:

$$I(X;Y) = D_{\mathrm{KL}}(p(x,y) \parallel p(x)p(y)) = \mathbb{E}_{p(x,y)}\left[\log\left(\frac{p(x,y)}{p(x)p(y)}\right)\right]$$

Точный расчёт требует наличия плотностей, которые в общем случае недоступны; есть лишь выборка $\{(x_i, y_i)\}_{i=1}^{N}$ из совместного распределения. Проблемы необходимости оценки плотностей позволяют избежать вариационные оценщики.

Предлагается выбрать, реализовать и провалидировать один из двух нейросетевых оценщиков: **MINE** (нижняя оценка, Belghazi et al., ICML 2018) или **CLUB** (верхняя оценка, Cheng et al., ICML 2020). На практике нижние оценки пригодны для максимизации ВИ (задачи сжатия, отбора признаков), верхние — для минимизации (unlearning, регуляризация).

Определения

MINE (нижняя граница). Из двойственного представления Донскера–Варадхана:

$$D_{\mathrm{KL}}(\mathbb{P} \parallel \mathbb{Q}) = \sup_{T}\left\{\mathbb{E}_{\mathbb{P}}[T] - \log \mathbb{E}_{\mathbb{Q}}\left[e^{T}\right]\right\}$$

При $\mathbb{P} = p(x,y)$, $\mathbb{Q} = p(x)p(y)$ и параметризации нейросетью-критиком T_θ:

$$I(X;Y) \geq \hat{I}_{\mathrm{MINE}}(\theta) = \mathbb{E}_{p(x,y)}[T_\theta(x,y)] - \log \mathbb{E}_{p(x)p(y)}\left[e^{T_\theta(x,y)}\right]$$

Равенство достигается при $T^* = \log\left(\frac{p(x,y)}{p(x)p(y)}\right)$. Математические ожидания оценивают по выборке: положительные пары (x_i, y_i) берут из совместного распределения, отрицательные получают перемешиванием в батче. Сеть учат градиентным подъёмом, максимизируя $\hat{I}_{\mathrm{MINE}}$.

CLUB (верхняя граница). При известной $p(y \mid x)$:

$$I_{\mathrm{CLUB}}(X;Y) = \mathbb{E}_{p(x,y)}[\log p(y \mid x)] - \mathbb{E}_{p(x)}\mathbb{E}_{p(y)}[\log p(y \mid x)]$$

Оценка Монте-Карло:

$$\hat{I}_{\text{CLUB}} = \frac{1}{N}\sum_i \log p(y_i \mid x_i) - \frac{1}{N^2}\sum_{i,j} \log p(y_j \mid x_i)$$

При неизвестной $p(y \mid x)$ её заменяют вариационным приближением; например, гауссианой: $q_\theta(y \mid x) = \mathcal{N}\big(y \mid \mu_\theta(x), \sigma^2_\theta(x) \cdot I\big)$. Подставляя q_θ в то же выражение, получают оценку vCLUB. Учат нейросеть через максимизацию правдоподобия: $\frac{1}{N}\sum_i \log q_\theta(y_i \mid x_i) \to \max$. При хорошем приближении vCLUB остаётся верхней оценкой.

Рекомендации

MINE.

1. Критик $T_\theta(x, y)$ с одним скалярным выходом.
2. Отрицательные пары получаются перемешиванием y в батче (сдвиг / `randperm`).
3. Член $\log \mathbb{E}[e^T]$ считать через log-sum-exp, иначе может произойти переполнение.
4. Наивный SGD-градиент этого лосса смещён; проблема решается через EMA по отрицательному члену.

CLUB.

1. Учат только на лог-правдоподобии $\mathbb{E}[\log q_\theta(y_i \mid x_i)]$, а не на полной оценке.
2. Полная оценка имеет сложность $\mathcal{O}(N^2)$; для больших батчей можно использовать “выборочную” версию (один случайный j на i), что даёт $\mathcal{O}(N)$.
3. Коллапс $\sigma^2_\theta \to 0$ при переобучении “взрывает” оценку; подумайте, как избежать этого.

Валидация

Гауссовская симуляция с известной ВИ: в качестве распределения (X, Y) берётся многомерное гауссово распределение размерности d с $\operatorname{corr}(x_i, y_j) = \delta_{ij}\rho$; истинное значение $I = -\frac{d}{2}\log(1-\rho^2)$. Меняя ρ, можно получить сетку значений ВИ (2–10 нат).

1. Проверьте, что MINE даёт $\hat{I} \le I$, CLUB $\hat{I} \ge I$.
2. Сделайте тест на независимость: при $\rho = 0$ метод должен давать ≈ 0.
3. Проверьте инвариантность: ВИ не меняется при биективных преобразованиях.

Критерий отбора: правильная реализация, подробный отчёт, абляционные эксперименты.